

Guri Teimoso

Análise de Internações Respiratórias em Canoas

João Vitor Munhoz, João Vitor Pereira, João Vitor de Souza, Lucas Vargas

Ciência de Dados (INF01090) — 2026/1

1. Objetivo

O sistema de saúde está frequentemente sobrecarregado e, sem métodos confiáveis para prever o volume e as causas das internações, as instituições de saúde têm dificuldade em se preparar para os momentos de maior demanda. Este projeto — denominado Guri Teimoso — busca preencher essa lacuna por meio do desenvolvimento de um modelo preditivo orientado a dados, com foco nas internações por causas respiratórias no município de Canoas, Rio Grande do Sul, Brasil. O objetivo principal é gerar estimativas diárias do número de internações respiratórias, permitindo um melhor planejamento de recursos e maior preparo das instituições de saúde locais em situações de emergência.

2. Base de Dados

A base de dados foi construída a partir da integração de três fontes independentes cobrindo a região de Canoas:

- SUS/DATASUS: Registros diários de internações por causas respiratórias do sistema público de saúde brasileiro, constituindo a variável-alvo (internacoes).
- INMET (Estação Jardim Botânico, Porto Alegre): Dados meteorológicos incluindo temperatura do ar, temperatura do ponto de orvalho, temperaturas mínima e máxima, umidade relativa, direção e velocidade do vento, rajada máxima de vento, pressão atmosférica, precipitação e radiação solar.
- FEPAM (Estação Parque Universitário, Canoas): Medições de qualidade do ar, incluindo concentrações de PM10, SO2, NO2, O3 e CO.

Após a combinação e limpeza dos dados, o dataset final contém 1.521 observações diárias. Algumas variáveis de poluição apresentaram índices relevantes de valores ausentes — por exemplo, PM10 com 58% e CO com 44% — o que foi tratado na etapa de pré-processamento. A variável-alvo internacoes foi completamente observada em todos os registros.

3. Metodologia

O projeto seguiu um pipeline composto por cinco etapas principais:

3.1 Dashboard de Análise Exploratória (Streamlit)

Para facilitar a compreensão dos dados e apoiar as decisões metodológicas ao longo do projeto, foi desenvolvido um dashboard interativo utilizando a biblioteca Streamlit. A aplicação organiza as análises em seis abas distintas:

- Geral: visão geral dos dados, com comparativos de séries temporais entre os atributos e as internações respiratórias.
- Clima: análises exploratórias focadas nas variáveis meteorológicas e sua relação com as internações.
- Demografia: análise demográfica das internações, perfil dos pacientes e informações sobre os hospitais presentes na base de dados.
- Base: visualização direta das colunas e registros da base de dados consolidada.
- Previsões: exibição das previsões geradas pelo modelo LSTM treinado.
- Infos: informações sobre as fontes de dados utilizadas (DATASUS, INMET e FEPAM).

O dashboard serviu como principal ferramenta de análise exploratória dos dados (EDA), permitindo identificar padrões sazonais, correlações entre variáveis ambientais e internações, e possíveis inconsistências nos dados que orientaram as etapas subsequentes do pipeline.

3.2 Pré-processamento dos Dados

Colunas irrelevantes foram removidas e os três datasets foram combinados pela coluna de data. Os valores ausentes foram tratados com MICE (Multiple Imputation by Chained Equations) e todas features foram normalizadas com MinMaxScaler e RobustScaler.

3.3 Feature Engineering

A coluna de data foi decomposta em campos de mês e dia da semana. Foram criadas variáveis binárias indicando fins de semana (`fim_de_semana`) e meses de inverno (`inverno`). Adicionalmente, foram geradas features de defasagem temporal para variáveis-chave — temperatura mínima (lags 1 a 3), umidade relativa (lags 1 a 3) e PM10 (lags 1 a 3) — com o objetivo de capturar os efeitos atmosféricos retardados sobre os desfechos de saúde. Então foi feito um holdout onde utilizamos os dados dos anos de 2020 à 2023 para treino, spot checking e otimização de hiperparâmetros e os dados de 2024 para teste.

3.4 Spot-Checking

Para estabelecer uma linha de base de desempenho e orientar a seleção do modelo final, oito algoritmos de regressão foram avaliados por meio de validação cruzada: Regressão Linear, ElasticNet, KNN, Árvore de Decisão, Random Forest, Gradient Boosting, HistGB e LightGBM. Utilizamos `TimeSeriesSplit` com $k = 5$ para validação cruzada, com o desempenho sendo avaliado pelas métricas MAE, RMSE e R^2 .

3.5 Modelo LSTM

Dada a natureza sequencial dos dados, uma rede neural LSTM (Long Short-Term Memory) foi selecionada como modelo final. A arquitetura foi treinada com uma janela de entrada de 7 dias para prever o número de internações do dia seguinte. Treinamos o modelo no conjunto de treino (2020 - 2023) e o modelo final foi avaliado em cima do conjunto de teste (2024) com os seguintes hiperparâmetros:

- hidden_size: 64
- num_layers: 2
- output_size: 1 (prevendo apenas internacoes)
- label_width: 1 (previsão para o dia seguinte)
- dropout: 0.1

4. Resultados

4.1 Resultados do Spot-Checking

Desempenho dos oito modelos baseline avaliados por validação cruzada (média ± desvio padrão):

Metric	Lin. Reg.	ElasticNet	KNN	Dec. Tree	Rand. Forest	Grad. Boost	HistGB	LightGB M
R ²	-0.217	-0.176	-0.238	-0.821	-0.277	-0.302	-0.504	-0.322
MAE	2.309	2.259	2.329	2.846	2.361	2.384	2.556	2.420
RMSE	2.986	2.937	3.023	3.659	3.062	3.089	3.313	3.118

O ElasticNet apresentou a melhor MAE mediana (2,259) e o menor RMSE (2,937) entre os modelos clássicos. A Árvore de Decisão obteve o pior desempenho em todas as métricas ($R^2 = -0,821$). Todos os modelos retornaram valores negativos de R^2 , indicando que nenhum deles conseguiu superar de forma consistente uma previsão pela média simples — resultado esperado dada a alta variabilidade dia a dia característica de contagens diárias de internações. Como os resultados não foram muito satisfatórios, decidimos criar um modelo LSTM.

4.2 Desempenho da LSTM

No conjunto de teste (a partir de 2024), a LSTM obteve:

MSE	MAE	RMSE	R ²
5.190	1.861	2.278	0.263

A LSTM alcançou um R^2 positivo de 0,263, representando uma melhoria expressiva em relação a todos os modelos baseline. Sua MAE de 1,861 também é inferior à de qualquer modelo avaliado no spot-checking, demonstrando que a arquitetura sequencial conseguiu capturar dependências temporais presentes nos dados. A análise de resíduos indicou que o modelo obteve melhor desempenho em dias com volume baixo a moderado de internações, com erros maiores nos períodos de pico — comportamento esperado em tarefas de regressão sobre contagens clínicas diárias. Um ponto que observamos é de que a LSTM final foi conservadora

nas suas predições, sempre se mantendo dentro de uma faixa estreita e não prevendo dias com muitas internações ou poucas internações.

4.3 Interpretabilidade (SHAP)

A análise SHAP foi aplicada ao modelo treinado para quantificar a contribuição de cada feature. As variáveis mais influentes foram a concentração de SO₂ (maior valor SHAP médio absoluto), o dia da semana, o indicador de fim de semana, a concentração de NO₂, a precipitação, a radiação solar e a rajada máxima de vento. Features relacionadas à temperatura e as defasagens de PM₁₀ apresentaram importância moderada, enquanto o indicador binário de inverno teve o menor impacto — sugerindo que padrões semanais e níveis de poluição são preditores de curto prazo mais relevantes do que marcadores sazonais.

5. Conclusões

Este projeto demonstrou que a integração de dados de saúde, meteorológicos e de qualidade do ar em um modelo unificado de séries temporais pode gerar melhorias significativas em relação a modelos de regressão clássicos para a previsão diária de internações respiratórias. O modelo LSTM, ao se beneficiar de sua capacidade de capturar dependências temporais em uma janela de 7 dias, superou todas as alternativas avaliadas.

A análise de importância das features revelou que variáveis de qualidade do ar — em especial SO₂ e NO₂ — e padrões temporais (dia da semana, fim de semana) são os principais fatores associados à variação de curto prazo nas internações, conferindo ao modelo um significado interpretável do ponto de vista da saúde pública.

Ainda assim, o desempenho absoluto do modelo permanece modesto. A elevada variabilidade intrínseca das contagens diárias de internações e o tamanho relativamente pequeno do dataset são fatores limitantes. Trabalhos futuros poderiam explorar previsões multi-horizonte, abordagens de ensemble combinando LSTM com modelos clássicos, e a incorporação de features adicionais como dados de vigilância epidemiológica (por exemplo, casos de influenza ou VSR) ou estratificações demográficas mais detalhadas.